

CODEIT AI 부트캠프 · 초급 프로젝트 · 1 팀 알까기포머

알약을 찾고, 알약을 설명하다

경구약제 객체검출 (Model A) + 복약정보 RAG (Model B)

99.94

최종 점수 · 74 종 채점 리더보드 ·
mAP@[0.75:0.95]

74 classes

공지에 없던 18 종을 직접 조달 · 확장

RF-DETR + YOLOv8m · 10-model WBF

김태윤 · 박예진 · 이하람 · 서동혁 · 박지수




“무엇인지” 보다 “어디인지” 가 점수를 지배한다

평가지표 mAP@[0.75:0.95] — 흔한 mAP@0.5 보다 훨씬 엄격한 겹침 기준


같은 예측 박스, 다른 채점

일반 대회 (IoU ≥ 0.5)



절반만 겹쳐도 정답 처리

이 대회 (IoU 0.75 ~ 0.95)



같은 박스가 오답 처리

클래스를 맞혀도 박스가 조금만 느슨하면 0 점 —
박스 정밀도 자체가 점수입니다.

232 장

훈련 데이터 전부 . 독립 구성은 114 개 ×
각도 3 장 — 트랜스포머 학습엔 절대 부족

51 : 1

클래스 불균형 . 56 종 중 17 종은
train 에 단 3 장

?

그리고 test 에는… 우리가 아직
모르는 무언가가 있었습니다

파일명이 데이터의 구조를 말해주고 있었다




EDA의 첫 단서 — 파일명에 인코딩된 K-code와 촬영 조건

K-001900-003544-016548_0_2_0_2_70_000_200.png

이미지에 포함된 알약들의 K-code (약품코드)

촬영 위도 (70° / 75° / 90°)


→ 같은 장면이 세 번 찍혀 있다




동일 배치 = 사실상 같은 사진 3장
232 장 ÷ 3 각도 ≈ 독립 구성 114 개.
이 구조가 뒤의 검증 설계를 결정합니다.

점 하나가 전수 검수를 열었다


BBox 중심점 산포도의 이상치 1 개 → 라벨링 오타 → 전체 라벨 전수 검수로 확장



x = 6,700+ ?! 이미지 폭은 976px



수정 전 — 박스가 이미지 밖



천의 자리 '6' 제거 → 정확히 맞춤

전수 검수 결과 — 총 18 건 수정

좌표 오타 (이상치) **1 건**

좌표 중복 기재 **다수**

BBox 완전 누락 **8 건**

category_id 뒤바뀜 **4 건 (2 쌍)**


누락 8 건 중 대부분은 같은 구성의 다른 각도 이미지와 대조해 자동 식별 —

모든 수정은 패치 딕셔너리로 코드화, 재빌드 시 자동 적용

수정하고 나서야 보인 구조


라벨을 고치자 숨어 있던 배치 규칙이 드러났다

BBox 중심점 — 6 개 위치 클러스터 (KMeans + $\pm 1\sigma$)



상·하단 각 좌 / 중 / 우 — 4 개 구성은 네 모서리, 3 개 구성은 삼각 배치.
각 클러스터의 중심과 $\pm 1\sigma$ 범위는 이후 합성 데이터의 배치 기준으로 그대로 활용됩니다.

착시의 해소 — 최소 알약 수



수정 전 — 2 개 구성 존재?

수정 후 — 최소 3 개

처음 코드로 집계했을 때는 2 개 구성 이미지가 있는 줄 알았지만, **박스 누락이 만든 착시**였습니다. 실제 구성은 3~4 개뿐 — 이 규칙도 합성 데이터의 구성 기준이 됩니다.

검증 점수를 부풀리지 않기

같은 장면 3 장이 train/val 로 갈라지는 순간 , 검증은 거짓말을 시작한다

무작위 분할

70°

train

75°

val

90°

train

학습에서 본 장면을 검증에서 또 본다
→ 점수 부풀림 (데이터 누수)

구성 (combo) 단위 그룹 분할

70°

75°

90°

같은 장면은 반드시
같은 쪽에만 존재

한 그룹 = 통째로 이동

StratifiedGroupKFold · 5-fold

Group

K-code 조합 — 각도만 다른 3 장을 1 그룹으로
(고유 114 그룹)

Stratify

이미지의 가장 희귀한 클래스 — 불균형 51:1
대응

재현성

seed 고정 — 모든 실험이 같은 분할 위에서
비교됨

이후 모든 학습 · 양상블이 이 분할 기준을 공유합니다 .

모델이 아니라, 로스에서 출발했다

지표가 로스를 결정하고, 로스가 모델을 결정한다

문제가 요구한 것

IoU 0.75+ 만 정답

겹침 자체를 직접 최적화하는
박스 로스가 필요

클래스 불균형 51:1

쉬운 다수에 묻히지 않고 어려운
소수에 집중하는 분류 로스

**알약이 다닥다닥 —
중복 박스는 치명적**

중복을 후처리 (NMS) 가 아니라
구조적으로 안 만드는 학습

RF-DETR 이 내장한 것

L1 + GloU

L1 은 좌표를, GloU 는 겹침을 —
서로의 약점을 메운다

Focal Loss

쉬운 샘플의 loss 를 깎아
희귀 클래스에 집중

**Hungarian
Matching**

예측과 정답을 1:1 로 짝지어
중복이 애초에 안 나온다

이 세 가지를 전부 내장한 모델이 **RF-DETR** 옅습니다 — 이름이 아니라 로스 구성으로 채택.

후보 검증 → RF-DETR Medium 확정

같은 기준 (동일 fold · 동일 데이터) 위에서 비교하고 결정

Swin-FPN	Swin-T + FPN, NMS 기반	baseline 비교
Swin-DETR	백본 교체 DETR — 랜덤 초기화, 수렴에 500ep	제외
DINO	CDN 등 핵심 기법 미구현 → 실익 없음	제외
RT-DETR	하이브리드 인코더 + Query Filtering	baseline 비교
RF-DETR	DINO 계보 흡수 + DINOv2 백본, 고 IoU 강점	채택

Baseline 비교 (1 fold · 100 epoch · mAP@[0.75:0.95])



변형 비교 — 동일 조건 5-fold 평균

Small 0.8739 vs **Medium 0.8776**

→ RF-DETR Medium (DINOv2 backbone) 확정

오류 분석 중 , 이상한 패턴이 보고되었습니다

“153 장을 가진 클래스가 ,
30 장짜리 클래스보다 못 맞습니다 .”

— 팀원의 오류 분석에서 나온 최초 문제 제기 . 20~30 장짜리 클래스들은 거의 100% 를 맞히고 있었습니다 .

데이터 양이
원인이 아니라면 ?



가설 A

데이터의 질 — 라벨이 오염됐다

가설 B


데이터의 분포 — test 가 train
과 다르다

두 가설, 두 개의 사실

가설은 세우는 것이 아니라 확인하는 것

가설 A · 라벨 오염

해당 클래스가 든 이미지를 전부 박스 좌표로 크롭해 한자리에 모아 봤습니다.



→ 사실이었다. A로 라벨링된 박스 안에 B가 있었다.
데이터의 양이 성능을 보장하지 않는다는 것을 수치로 확인.

가설 B · 분포 차이

“test는 각도나 배치가 다른가?”를 확인하려 test 이미지를 직접 열어봤습니다.

각도가 문제가 아니었습니다.

**56종 어디에도 없는
알약이 보였습니다.**

→ 예상 밖의 사실. 분포 문제가 아니라, 문제 정의 자체가 우리가 알던 것과 달랐습니다.

“test 40 종” 은 사실이 아니었다

test 전수 검수 — 그리고 대회 측의 공식 확인

대회 공지

실제 (전수 검수)

train	56 종	56 종 (일치)
test	40 종	56 종 전부 + 미지의 18 종

주어진 문서를 그대로 믿었다면 끝까지 몰랐을 사실 .

대회 측 공식 회신

test-only 클래스는 의도된 설계이며 채점 대상 —
각 팀이 직접 수집 · 라벨링해야 한다


직접 찾아낸 18 종 (N 종)



AIHub 에서 이미지 확보 → SAM 세그멘테이션 → 1,750 장 육안 검수 →
74 종 외 알약이 끼지 않도록 필터링해 학습 가능한 형태로 확보

라벨은 만들 수 있는데, ID 를 모른다

제출에는 대회 규격 category_id 가 필요 — 그런데 그 숫자의 출처를 아무도 몰랐다



**ConnectDI dl_idx + 1 = 대회
category_id**

약품명만 알면 제출용 ID 를 복원하는 경로 확보 → 56 종에서 74 종으로, 모든 학습 · 제출을 재편

점수 하나로 채점의 구조를 역산하다

18 종 ID 가 as_is 인지 +1 인지 — 확인할 방법은 제출뿐이었다

관찰

두 버전 (as_is / +1) 을 제출 —
점수가 소수점 5 자리까지 동일

0.98544

= 0.98544

추론

18 종의 AP 가 0 이라면 점수 상한은

56 / 67 ≈ 0.836

그런데 실제 점수는 0.98544 —
상한을 훌쩍 넘는다

∴ 증명

Public 채점 GT 에
18 종이 아예
포함되지 않았다

이 증명에서 따라온 세 가지 결정

+1 여부는 **public** 으로 영원히 판별 불가

→ 추가 제출 시도 중단 — 시간 절약

“채점한다” 했으니 **private** 엔 있다

→ 최종 슬롯 2 개를 as_is / +1 로 헤지


56 종 (0.98) → 67 종 (0.98544) 상승 = FP 감소

→ 미지 알약이 신규로 빠지며 오탐 정리 → 74 종 유지 근거

수치 목표를 버리고, 분포를 택했다

라벨 오염을 겪은 뒤 생긴 습관 — 새 데이터도 오염을 전제하고 크롭 전수 검사


검수에서 발견 — “클래스당 42 장” 을 좇던 구축



타겟 한 종만 남기고 나머지를 전부 마스킹
—
수치는 달성, 그러나 **test** 는 조합
이미지.
분포가 오히려 멀어지고 있었다

빈 배경을 잡은 박스들이 크롭 검수에서 발각 — 에러는 한 줄도 없었다

재설계 — 조합을 살리고, 밖의 것만 가린다



“42 장” 숫자를 포기 (± 허용) —
조합 이미지는 그대로 유지,
74 종 밖의 알약만 마스킹

2,895 → 2,538 장 : 감소분이 정확히 중복 · 훼손 사본의 수

마스킹 데이터셋 **2,705 장** · **7,943 boxes** · **71 종** (오염 65 장 삭제 · 미확보 3 종과 합성 pool 의 병합은 다음 장에서)

합성 vs 마스킹 — 같은 조건에서 붙였다

팀이 만든 두 데이터 설계를 RF-DETR Medium 동일 조건으로 통제 비교

합성 방식 — 누끼 + inpainting 배경

클래스당 35 개 · 약 800 장 (232 + 합성 600)

0.9315

배경 · 크기 · 회전 · 그림자 — 증강 효과가 강한 데이터

마스킹 방식 — 실제 조합 이미지 유지

클래스당 45 개 이상 · 약 2,700 장 (71 종)

0.9524

원본 분포 그대로 — 증강 효과가 약한 데이터

왜 마스킹이 이겼나

데이터 양

클래스당 35 vs 45+,
이미지 800 vs 2,700 장

증강 강도

train/test 가 유사한 미션 —
증강이 약한 쪽이 유리했다

클래스 집중

56 종 채점 기준, 56 종 합성 > 74 종 합성 —
클래스 수만큼 데이터가 더 필요하다

승자독식 대신 병합 마스킹 주축 + 미확보 3 종 반영 + 합성 600 장 보강 = **3,500 장 · 74 종 완성 · 클래스당 ~70 개**

최종 파이프라인

데이터 → 학습 → 추론, 모든 판단이 한 줄로 이어진다

데이터

- 원본 per-box JSON 763 개 → COCO 통합
- 라벨 교정 코드화 (패치 딕셔너리)
- StratifiedGroupKFold 5-fold
- 18 종 외부 조달 · 조합 유지 마스킹
- 마스킹 + 합성 병합 → 3,500 장 / 74 종

학습

- RF-DETR M(576) + YOLOv8m · 각 5-fold
- loss: Focal + L1 + GloU (Hungarian)
- lr 1e-4 · cosine · 100ep · batch 16
- Early stopping (patience 10)
- HorizontalFlip OFF — 각인 보존

추론 · 제출

- test 842 장 × 10 개 모델 개별 추론
- WBF 앙상블 (iou_thr 0.55)
- 저 threshold 제출 (rank 기반 mAP)
- 내부 id → K-code 역매핑
- as_is / +1 두 버전 헤지 제출

점수의 성질을 아는 만큼 짜낼 수 있다

채점 방식 자체를 전략의 재료로 사용

10-model WBF 앙상블

RF-DETR 5 개 + YOLOv8m 5 개가 낸 박스 중 IoU 0.55 이상 겹치는 것을 같은 알약으로 묶어 score 가중 평균으로 합성 .

DETR 계열 + CNN 계열의 “합의” 로 박스가 정밀해진다
— 고 **IoU** 지표에서 이 정밀화가 곧 점수

저 threshold 제출

mAP 는 절대 score 가 아니라 rank 기반 — 예측을 score 순으로 정렬해 PR 곡선 면적을 계산 .

저신뢰 오답은 곡선 꼬리에 붙을 뿐 , 고신뢰 정답의 면적을 깎지 않는다 → **threshold 0.001** 로 누락 (FN) 최소화


병렬 트랙의 진단 기여

팀 병렬 실험 (0.789→0.891) 이 같은 문제를 다른 각도에서 진단 .

bbox inflation 의 원인 규명 · **best checkpoint** 기준을 채점 지표 **mAP@[0.75:0.95]** 에 정렬해야 함을 확인

결과 — 두 개의 리더보드

56 종만 채점하는 기존 무대 , 그리고 18 종까지 채점하는 새 무대



■ 56 종 채점 리더보드 (18 종은 오탐 감소용) ■ 56+18 종 채점 리더보드 — 준비해 둔 18 종이 점수가 되는 무대

99.94


최종 점수 · 74 종 채점 리더보드
mAP@[0.75:0.95]

18 종을 준비해 둔 것이 , 18 종이 채점되는
무대에서 진가를 발휘했습니다 .

**RF-DETR 5-fold 99.88 → YOLOv8m 5-
fold 를 더한 10-model WBF 로 99.94.**

찾은 알약에게, 말을 걸다 — Model A + RAG

검출 결과 (drug_id) 를 그대로 검색 키로 쓰는 복약정보 파이프라인 (Model B · 기본 수준)



drug_id 를 먼저 걸고 검색합니다 — 다른 약의 문서가 답변에 섞여 들어오는 것을 원천 차단 (의약 도메인의 안전 요건)

Tier 1 — 안전 필수 정보

효능 · 용법용량 · 경고 / 금기 등은 LLM 생성이 아닌
원문 고정 출력 — 환각이 끼어들 자리를 없앤다

결정적 (deterministic) 응답

Tier 2 — 자유 질의

“식후에 먹어야 하나요?” 같은 자연어 질문은
drug_id 필터를 거친 RAG 로 근거 기반 답변

검색 증강 생성 (RAG)

시연 — 사진 한 장에서 복약 안내까지

 (알약 사진 업로드) 이 약들 뭐예요?

검출 결과 3 건 — 타이레놀정 · 울트라셋정 · ...

각 알약의 위치와 신뢰도 표시 (Model A)

이거 식후에 먹어야 하나요?

복용법 근거 기반 답변 + 출처 표기

drug_id 필터 → 해당 약 문서에서만 검색 (Model B)

이 시연이 보여주는 것

검출이 곧 검색 키

Model A 의 class 예측이 그대로 RAG 의 drug_id 필터가 된다 — 두 모델이 한 서비스로

안전이 기본값

핵심 복약 정보는 고정 출력, 해석이 필요한 질문만 생성 — 의약도메인 설계

프로젝트의 방점

메인은 Model A. RAG 는 “이 검출로 무엇을 할 수 있는가” 를 보여주는 기본 수준의 확장

이 프로젝트가 남긴 것

**데이터의 양은
성능을 보장하지 않는다**

153 장 클래스의 부진 → 라벨 오염 규명

**주어진 문서를
데이터로 확인한다**

“test 40 중” 공지는 사실과 달랐다 → 18 종 발견

**수치 목표보다
분포 적합성이 먼저다**

“42 장” 을 버리고 조합 이미지를 살렸다

**점수는 읽는 것이 아니라
해석하는 것이다**

0.98544 에서 채점 구조를 역산 → 전략 변경

**증강이 항상
이득은 아니다**

train/test 가 유사하면 약한 증강이 유리 (0.9315 vs 0.9524)

**클래스 수만큼
데이터가 필요하다**

110 종 대신 74 종 집중이 클래스당 정확도를 지켰다

감사합니다 — 1 팀 알까기포머

THANK YOU

Q & A

궁금하신 점을 편하게 질문해 주세요 .

1 팀 알까기포머

김태운 · 박예진 · 이하람 · 서동혁 · 박지수

가상 오피스에서 함께 달린 지난 4 주였습니다 →



알까기포머 가상 오피스

매일 아침 이곳에서 모여 오늘의 실험을 나누고 , 밤에는 서로의 학습 로그를 교차
검수했습니다 .